lab09

AUTHOR
Otavio Ribeiro Mello

```
library(reticulate)
py_install(c("pandas", "plotnine"))
```

```
Using virtual environment '/cloud/project/r-reticulate' ...

+ /cloud/project/r-reticulate/bin/python -m pip install --upgrade --no-user pandas plotnine
```

1. Importe o conjunto de dados diamonds, cujo arquivo está disponível no website da disciplina.

```
import pandas as pd
from plotnine import *
from plotnine.data import diamonds
```

```
print(diamonds.head())
```

```
   carat      cut color clarity  depth  table  price     x     y     z
0   0.23    Ideal     E     SI2   61.5   55.0    326  3.95  3.98  2.43
1   0.21  Premium     E     SI1   59.8   61.0    326  3.89  3.84  2.31
2   0.23     Good     E     VS1   56.9   65.0    327  4.05  4.07  2.31
3   0.29  Premium     I     VS2   62.4   58.0    334  4.20  4.23  2.63
4   0.31     Good     J     SI2   63.3   58.0    335  4.34  4.35  2.75
```

2. Crie uma visualização de dados que descreva a associação existente entre as variáveis peso (carat) e preço (price). Que ações você tomou para garantir que você produziu um gráfico de boa qualidade? Escreva um parágrafo comunicando os seus achados.

```
grafico_peso_preco = (
    ggplot(diamonds, aes(x="carat", y="price"))
    + geom_point(alpha=0.1, size=0.5, color="#D55E00")
    + theme_minimal()
    + labs(
        title="Relação entre Peso e Preço dos Diamantes",
        x="Peso (Quilates)",
        y="Preço (USD)"
    )
)
print(grafico_peso_preco)
```

```
<ggplot: (640 x 480)>
```

Ações para garantir um gráfico de boa qualidade: Como o conjunto tem mais de 53 mil observações reduzi o tamanho dos pontos (`size = 0.5`) e usei transparência alta (`alpha = 0.1`), de modo que regiões mais densas aparecem mais escuras. Também escolhi um tema limpo (`theme_minimal`), uma cor única e discreta, e coloquei título e rótulos de eixos informativos, com as unidades (quilates e dólares).

Existe uma associação entre peso e preço: diamantes mais pesados tendem a ser mais caros. Além disso, a dispersão do preço é maior nos diamantes mais pesados, ou seja, para um mesmo peso há uma variação grande de preços, o que indica que outras características (corte, cor, clareza) também influenciam o valor. A maior parte dos diamantes está concentrada em pesos baixos e preços baixos.

3. A relação identificada na questão anterior é a mesma relação presente nos diferentes cortes de diamantes? Crie uma visualização que demonstre seus achados eficientemente. Descreva sua conclusão em um parágrafo.

```
grafico_corte = (
    ggplot(diamonds, aes(x="carat", y="price", color="cut"))
    + geom_point(alpha=0.2, size=0.5)
    + facet_wrap("~cut")
    + theme_minimal()
    + theme(legend_position="none")
    + labs(
        title="Peso vs Preço por Qualidade do Corte",
        x="Peso (Quilates)",
        y="Preço (USD)"
    )
)
print(grafico_corte)
```

```
<ggplot: (640 x 480)>
```

Conclusão: A relação positiva entre peso e preço se mantém em todos os tipos de corte. No entanto, é visível que os cortes de qualidade superior, “Ideal” e “Premium”, atingem preços máximos com quilates menores, apresentando uma curva mais inclinada. Em contraste, o corte “Fair” exige diamantes significativamente mais pesados para alcançar a mesma faixa de preço alto. Assim, a tendência geral é a mesma, mas a inclinação e a dispersão da relação variam conforme a qualidade do corte.

4. Crie uma visualização que mostre a relação entre preço e peso do diamante, considerando as diferentes combinações de qualidade de corte, cor e clareza do diamante. Quais foram as dificuldades encontradas? A relação entre preço e peso é a mesma para diferentes configurações de diamantes?

```
grafico_complexo = (
    ggplot(diamonds, aes(x="carat", y="price", color="cut"))
    + geom_point(alpha=0.3, size=0.5)
    + facet_grid("color ~ clarity")
    + theme_minimal()
    + theme(figure_size=(14, 10))
    + labs(
        title="Relação Preço x Peso cruzada por Cor e Clareza",
        x="Peso (Quilates)",
        y="Preço (USD)"
    )
)
print(grafico_complexo)
```

```
<ggplot: (1400 x 1000)>
```

Dificuldades encontradas: Cruzar três variáveis categóricas (`cut`, `color` e `clarity`) com a relação entre peso e preço gera muitos painéis (7 cores × 8 clarezas), o que exige um gráfico grande (`figure_size = (14, 10)`) para manter a leitura possível. Como o corte foi mapeado na cor dos pontos e não em facetas, a sobreposição entre cortes dentro de cada painel dificulta distingui-los. Além disso, algumas combinações têm poucas observações, o que torna a tendência difícil de avaliar nesses painéis.

A relação é a mesma para diferentes configurações? A relação positiva geral entre preço e peso continua sendo a mesma em todas as configurações. O que muda drasticamente é a inclinação da curva e a dispersão: combinações de alta clareza (ex.: IF, VVS1) e melhor cor (D, E) apresentam um aumento de preço muito rápido com um peso mínimo, enquanto combinações piores (cor J, clareza I1) mostram um crescimento muito mais lento e achatado por conta da menor qualidade.

```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

```
[1] "2026-10-21 21:34:55 -03"
```